



Universidad de San Carlos de Guatemala
Escuela de Ciencias Físicas y Matemáticas

Programación 1

Práctica 2 — Análisis Exploratorio de Datos con Python



Práctica 2

Análisis Exploratorio de Datos con Python

Instrucciones generales

- Esta práctica tiene **1 ejercicio** de **100 puntos**.
- La entrega es a través de **U Virtual**: suba el enlace de GitHub que apunte directamente al archivo `practicas/python/analisis_datos/notebooks/analisis_estrellas.ipynb` en su fork del repositorio.
- El notebook debe ejecutarse completamente **sin errores** (celdas con resultados visibles) antes de hacer el commit.
- Consulte la documentación oficial de cada librería; los enlaces están en el mismo notebook y en la referencia rápida al final de este documento.
- No se permite copiar código de compañeros. Está permitido y recomendado consultar la documentación oficial.

¿Qué es Kaggle?

Kaggle ([kaggle.com](https://www.kaggle.com)) es la plataforma de ciencia de datos más grande del mundo. Ofrece:

- **Datasets públicos**: miles de conjuntos de datos listos para analizar, en formatos como CSV, JSON o SQLite.
- **Competencias**: empresas y organizaciones publican problemas reales con premios en efectivo.
- **Notebooks en la nube**: entorno Jupyter gratuito con GPU para entrenar modelos de *machine learning*.
- **Cursos gratuitos**: introductions a Python, Pandas, Machine Learning, etc.

En esta práctica usaremos Kaggle únicamente para descargar un dataset. Crear una cuenta es **completamente gratuito**: solo requiere un correo electrónico, sin tarjeta de crédito ni costo alguno.

El dataset: Stars Dataset

Fuente: kaggle.com/datasets/waqi786/stars-dataset

Este dataset contiene **1 000 estrellas** con **28 clases espectrales** distintas, con las siguientes columnas:

Columna	Tipo	Descripción
Name	str	Nombre de la estrella
Distance (ly)	float	Distancia en años luz
Luminosity (L/L _o)	float	Luminosidad relativa al Sol ($L_{\odot}$)
Radius (R/R _o)	float	Radio relativo al Sol ($R_{\odot}$)
Temperature (K)	float	Temperatura superficial en Kelvin
Spectral Class	str	Clase espectral (A7V, G2V, M3.5V, ...)

Ejercicio 1: Análisis Exploratorio de Datos**100 pts****Descripción**

Completa el notebook `analisis_estrellas.ipynb` realizando un **análisis exploratorio de datos** (*EDA, Exploratory Data Analysis*) sobre el dataset de estrellas. El notebook ya tiene la estructura con instrucciones y enlaces a la documentación; tu tarea es escribir el código en cada celda marcada con **# tu código aquí**.

Parte A — Configuración del ambiente y carga de datos**20 pts**

El proyecto usa **Poetry** para gestionar las dependencias de Python. Poetry es una herramienta que declara las librerías necesarias en un archivo `pyproject.toml` y crea un ambiente virtual aislado.

Configurar el ambiente con Poetry

```
# Desde la carpeta practicas/python/analisis_datos/
poetry install          # instala numpy, pandas, matplotlib, seaborn, jupyter

# Abrir Jupyter Notebook dentro del ambiente:
poetry run jupyter notebook

# O con JupyterLab (interfaz más moderna):
poetry run jupyter lab
```

En la **Sección 1** del notebook debes:

1. **Importar** las cuatro librerías con sus alias convencionales: `numpy` as `np`, `pandas` as `pd`, `matplotlib.pyplot` as `plt`, `seaborn` as `sns` (5 pts)
2. **Cargar el CSV** usando `pd.read_csv()` y guardarlo en una variable llamada `stars` (5 pts)
3. **Mostrar las primeras filas** con `stars.head()` (5 pts)
4. Verificar las **dimensiones** con `stars.shape` y los **tipos de datos** con `stars.dtypes` (5 pts)

pts)

Parte B — Exploración estadística y comparación de técnicas**35 pts**En la **Sección 2** del notebook debes:

1. Obtener **estadísticas descriptivas** usando `stars.describe()` (5 pts)
2. Verificar **valores nulos** con `stars.isnull().sum()` (4 pts)
3. Contar estrellas por **clase espectral** con `.value_counts()` (4 pts)
4. Calcular la **temperatura media de las estrellas de clase espectral A7V** con un **ciclo for**: filtrar el DataFrame para esa clase, recorrer la columna acumulando la suma y dividir entre el conteo (8 pts)
5. Calcular la temperatura promedio para **todas las clases a la vez** con `.groupby().mean()` y comparar con el resultado anterior — observa cómo una sola línea de pandas reemplaza el ciclo completo (6 pts)
6. Con **NumPy**: calcular media, mediana y desviación estándar del array de temperaturas con `np.mean()`, `np.median()`, `np.std()` (4 pts)
7. Con **NumPy**: calcular los percentiles 25, 50, 75 y 90 del radio estelar con `np.percentile()` (4 pts)

¿Por qué practicar el ciclo for si pandas lo hace en una línea?Entender el algoritmo detrás de `groupby` te permite:

- Depurar errores cuando los resultados son inesperados.
- Implementar operaciones personalizadas que pandas no ofrece directamente.
- Apreciar por qué las funciones vectorizadas son más eficientes y legibles.

Parte C — Visualizaciones**30 pts**En la **Sección 3** del notebook debes crear **4 gráficas**:

1. **Gráfica de barras** — cantidad de estrellas por tipo (usa `matplotlib` o el método `.plot(kind='bar')`) (7 pts)
2. **Boxplot** — distribución de temperatura por clase espectral (usa `seaborn.boxplot`) (8 pts)
3. **Scatter plot** — Temperatura vs. Luminosidad, coloreado por clase espectral (usa `seaborn.scatterplot` con escala logarítmica en el eje Y) (8 pts)
4. **Diagrama Hertzsprung-Russell** — igual que el scatter anterior pero con **ambos ejes en escala logarítmica** y el eje X invertido (las estrellas más calientes a la izquierda) (7 pts)

¿Por qué usar escala logarítmica?

La luminosidad de las estrellas varía en **12 órdenes de magnitud**: desde $0,00008 L_{\odot}$ (enanas blancas frías) hasta $849\,420 L_{\odot}$ (hipergigantes). En escala lineal la mayoría de los puntos quedarían aplastados. La escala logarítmica permite ver *todos* los grupos con claridad.

Parte D — Estadísticas vectorizadas con NumPy**20 pts**

NumPy opera sobre **arrays enteros** sin necesidad de ciclos `for`, lo que lo hace mucho más rápido que las listas de Python para cálculos numéricos.

En la **Sección 4** del notebook debes:

1. Extraer la columna de temperaturas como array NumPy usando `.values` y verificar su tipo con `type()` (4 pts)
2. Calcular media, mediana y desviación estándar de la temperatura (6 pts)
3. Calcular los percentiles 25, 50, 75 y 90 del radio estelar (5 pts)
4. Convertir las temperaturas de Kelvin a Celsius **de forma vectorizada** (sin usar ciclos) con la operación `celsius = temperaturas - 273.15` (5 pts)

Operaciones vectorizadas

`temperaturas - 273.15` resta 273.15 a *todos* los elementos del array de una sola vez. Es equivalente a un `for` pero cientos de veces más rápido y más legible.

Estructura del repositorio

```
su-repositorio/  
practicas/  
python/  
analisis_datos/  
notebooks/  
analisis_estrellas.ipynb  ← su archivo (copia del notebook estudiante)  
data/  
star_dataset.csv         ← dataset (descargado de Kaggle)  
pyproject.toml           ← dependencias de Poetry (ya incluido)
```

Descargar el dataset

1. Crear una **cuenta gratuita** en [kaggle.com](https://www.kaggle.com) — solo requiere correo electrónico; sin tarjeta ni costo.
2. Iniciar sesión e ir al dataset: [kaggle.com/datasets/waqi786/stars-dataset](https://www.kaggle.com/datasets/waqi786/stars-dataset).
3. Hacer clic en el botón **Download** (esquina superior derecha).
4. Descomprimir el archivo descargado y copiar `star_dataset.csv` a la carpeta `practicas/python/analisis_datos/data/` del repositorio.

Rúbrica de evaluación

Parte	Criterio	Pts
A	Imports correctos con alias convencionales	5
A	<code>read_csv</code> carga el archivo sin error	5
A	<code>head()</code> muestra las primeras filas	5
A	<code>shape</code> y <code>dtypes</code> mostrados	5
B	<code>describe()</code> genera estadísticas	5
B	<code>isnull().sum()</code> verifica datos faltantes	4
B	<code>value_counts()</code> cuenta clases espectrales	4
B	Ciclo <code>for</code> : filtrar dataset + calcular media manualmente	8
B	<code>groupby().mean()</code> para todos los tipos + comparación	6
B	NumPy: media, mediana, desv. estándar	4
B	NumPy: percentiles del radio	4
C	Gráfica de barras (tipos de estrella)	7
C	Boxplot temperatura por clase espectral	7
C	Scatter Temperatura vs Luminosidad (log)	8
C	Diagrama HR (ambos ejes log, eje X invertido)	8
D	Extracción de array NumPy con <code>.values</code>	4
D	Estadísticas NumPy (media, mediana, std)	6
D	Percentiles NumPy	5
D	Conversión vectorizada $K \rightarrow ^\circ C$	5
Total		100

Referencia rápida — Documentación oficial

NumPy

- `numpy.mean` — media aritmética
- `numpy.median` — mediana
- `numpy.std` — desviación estándar
- `numpy.percentile` — percentiles

Pandas

- `pandas.read_csv` — cargar archivos CSV
- `DataFrame.head` — primeras n filas
- `DataFrame.describe` — estadísticas descriptivas
- `DataFrame.isnull` — detectar valores nulos
- `Series.value_counts` — contar ocurrencias
- `DataFrame.groupby` — agrupar y agregar

Matplotlib

- `pyplot.figure` — crear figura y definir tamaño
- `pyplot.bar` — gráfica de barras
- `pyplot.yscale` — escala del eje Y (e.g. 'log')

Seaborn

- `seaborn.boxplot` — diagrama de caja por categoría
- `seaborn.scatterplot` — diagrama de dispersión con colores

“In God we trust; all others must bring data.”
— W. Edwards Deming